

빅데이터 분석 정의서

주제 : 서울지역 집값 분석
(편의시설 및 범죄율이 집값에 관련이 있는가?)

2026.02.06.(금)

I. 개요

1. 아이디어 주제

: 서울지역 집값이 편의시설 및 범죄율이 집값에 유의미한가?

2. 개발 목표

: 서울시 500m 격자 단위로 편의시설(교통, 생활, 환경) 인프라 점수와 범죄지수를 산출, 이를 기반으로 3/6/9/12개월 후 전/월세 가격을 예측하는 VFM 종합지수 시스템을 개발하여 2030세대에게 최적의 가성비 주거지를 추천

3. 개발 내용

- : 1. 서울시 전역을 500m × 500m 격자(약 5,800개)로 분할하여 공간 분석 단위 구축
2. 편의 시설별 최적 반경 기반 접근성 점수 산출
 - ※ 지하철 800m, 버스 800m, 음식점 200m, 은행 500m, 공원 500m, 병원 300m~2km 등
3. 자치구별 5대 범죄 발생 건수를 격자 단위 범죄지수로 변환
4. GBR(Gradient Boosting Regressor)모델로 미래 시세 예측
5. MLP(Multi-Layer Perceptron) 모델로 인프라 기반 적정가치 산출
6. VFM 지수 = GBR 예측가 / MLP 적정가치 (값이 클수록 저평가된 가성비 좋은 지역)

II. 기능별 빅데이터 분석 명세서

기능명	데이터 기반 청년 주거지 추천 및 월세 예측 시스템
1. 데이터 준비	
데이터 정의	타겟 데이터 (종속변수): 서울시 아파트 실거래가, 아파트명, 전용면적, 계약일, 거래금액, 도로명주소
	인프라 데이터 (독립변수): 교통 시설, 전국 버스정류장 위치(위도·경도), 서울 지하철역 위치 및 역사 정보, 생활 및 문화 시설 서울시 주요 공원 현황, 금융기관(은행) 위치 정보 영화상영관, 휴게음식점, 병·의원 현황
	안전 데이터 (독립변수): 치안 및 안전시설, 경찰서와 파출소 위치 정보, 안심 귀갓길 및 안전 비상벨 위치, CCTV 설치 현황
	범죄 통계:서울시 자치구별 5대 범죄 발생 건수 현황
	경제 지표 (통제 변수): 거시경제 지표, 한국은행 기준금리, 소비자물가지수(CPI)
데이터 획득 방법	공공데이터 (API/CSV) 서울 열린 데이터 광장 및 공공데이터 포털을 통해 정형 데이터를 수집 주소 및 위·경도 좌표 정보를 포함한 인프라(지하철, 버스, 공원, 병원)와 범죄 통계 데이터를 확보

	웹 크롤링 (Crawling): 공공데이터로 제공되지 않는 금융기관(은행 등)의 위치 정보를 지도 서비스나 포털에서 자체 수집하여 보완 카카오 API 이용하여 크롤링		
	시스템 연계 (Open API): 국토교통부의 아파트 실거래가 정보와 한국은행(ECOS)의 경제 지표(금리, 물가)를 API로 연계하여 2014년부터 2025년까지의 시계열 데이터를 구축		
	데이터양: 2014년~2024년(약 11년) 간의 서울시 전역 아파트 거래 내역 및 관련 인프라 전수 데이터		
수집 데이터	부동산 실거래: 단지명, 전용면적, 계약 연월일, 거래금액(만원), 도로명주소, 지번 주소		
	교통 인프라: 버스정류장 명, 정류장 번호, 위도, 경도, 지하철 역명, 호선, 역위치 좌표		
	생활 편의시설: 공원 명, 공원위치, 금융기관명, 주소, 업종명(병원/의원/영화관/음식점), 시설 좌표		
	치안 및 안전: 경찰서명, 파출소명, 주소, CCTV 설치대 수, 안전 비상벨 위치, 안심 귀갓길 경로 정보		
	범죄 및 경제: 자치구별 5대 범죄 발생 건수(살인, 강도, 강간, 절도, 폭력), 기준금리, 소비자물가지수(CPI)		
	2. 전처리		
전처리 과정	단계	처리 내용	
	공간 정규화	서울시 전역을 500m×500m 격자(5,832개)로 분할, 모든 데이터를 grid_id 기준으로 매핑	
	좌표 변환	위도·경도를 미터 단위로 변환하여 반경 계산	
	편의시설 반경별 집계	cKDTree 알고리즘으로 시설별 최적 반경 내 개수 집계	
	인프라 점수 산출	Min Max 정규화 후 카테고리별 가중 합산	
	범죄지수 산출	자치구별 5대 범죄 발생 건수를 인구수 대비 지수화, 격자 단위로 배분	
	시계열 피쳐 생성	LAG 변수 생성 (1, 3, 6, 9개월 전 가격 및 금리)	
	타겟 변수 생성	날짜 기반 매칭으로 3, 6, 9, 12개월 후 가격 생성	
	결측치 처리	타겟 변수 기준 결측 제거 (미래 데이터 없는 최근 12개월 제외)	
전처리 데이터	데이터명	기간/형태	설명
	범죄자 수	월별, 2014.01~2024.12	격자별 grid_crime_index (0~1 정규화)
	infra_score	단일 값 (정적)	교통, 생활, 환경 종합
	전/월세 가격	2014.01~2024.12	중앙값(deposit_median), 평균값, 거래량, 전용면적별 분류
	거시경제	2015.01~2024.12	기준금리, CPI, 실질금리, LAG 변수

	최종데이터	2015.10~2024.12	640,844행 × 47열, 격자×월×주거 크기별	
3. 데이터 분석				
데이터 분석 목표	2030을 위한 종합지수를 활용한 부동산 예측			
데이터 분석 시나리오	대한민국 2030세대 사람들이 신규 입학, 복학, 취업, 결혼 등 서울에서 생활할 때 새로운 집으로 이사를 가야 하는데 현재 자금이 부족해서 또한 종합지수가 높은 곳에서 살고 싶어서 부동산 예측			
데이터 분석 결과	1. 가설: 인프라(교통+생활편의) 상위 30% 지역이 월세 20% 이상 높다. 2. 결과: 기각 (오히려 인프라 상위 지역이 14~35% 낮음) 3. 원인: 인프라 밀집 지역에 소형 주거 집중 → 평균가 하락 효과 4. 크기 통제 시: 전세 초소형/중형에서만 1~2% 프리미엄 확인 5. 핵심 인사이트: 인프라는 가격보다 가성비(VFM)를 높이는 방향으로 활용 6. 상관관계 분석: 범죄지수와 월세 가격: 음의 상관관계 (범죄 높을수록 가격 낮음) 인프라 점수와 거래량: 양의 상관관계 (인프라 좋을수록 거래 활발)			
4. 모델 생성 및 학습				
모델링 목표	2030을 위한 종합지수를 활용한 부동산 예측			
학습 모델	GBR / MLP ※ LSTM, XGBoost도 테스트 했으나, 2030 청년층의 월세 비중을 고려하여 전체 예측 1위인 GBR으로 최종 선택			
학습 방법	모델	역할	입력 피처	출력
	GBR	시계열 미래 시세 예측	total_deposit_median, trade_count, BASE_RATE, CPI_YOY, deposit_lag_1/3/6/9, base_rate_lag_3/6/9, cpi_yoy_lag_3/6/9, base_rate_diff_3 (15개)	pred_3m, pred_6m, pred_9m, pred_12m
	※ LSTM 하이퍼 파라미터:units 64, dropout 0.2, epochs 100, batch_size 32			
	MLP	정적 인프라 기반 적정가치 산출	safety_score_scaled, grid_crime_index, trans_index, conv_index, env_index (5개)	fair_value
	VFM = GBR 예측 시세 / MLP 적정가치 VFM > 1: 인프라 대비 저평가 (가성비 좋음) VFM < 1: 인프라 대비 고평가			
모델 예측 결과	↓ R ² Score 월세			
	기간	GBR	LSTM	XGB
	3개월 후	0.7908	0.7747	0.7662
	6개월 후	0.7482	0.7529	0.7284
	9개월 후	0.7241	0.7374	0.6961
	12개월 후	0.7329	0.7219	0.6866

	↓ R ² Score 전세												
	기간		GBR		LSTM		XGB						
	3개월 후		0.8354		0.7999		0.8035						
	6개월 후		0.8116		0.7757		0.7843						
	9개월 후		0.8036		0.7544		0.7704						
	12개월 후		0.7942		0.7529		0.7594						
	※ 최고 성능: 전세 3개월 GBR R ² =0.8354, 월세 3개월 GBR R ² =0.7908												
	↓ MLP + GBR 결합 (VFM 산출) 결과												
	항목				값								
	분석 기간				2015-10 ~ 2024-12 (111개월)								
	월세 데이터				644,915건								
	전세 데이터				649,718건								
	분석 격자수				월세 1,732개 / 전세 1,730개 (500m x 500m)								
	↓ 월세 통계 (만원)												
	GBR - 12개월 기준			MLP fair_value 통계			VFM 지수 - 12개월						
	항목		값		항목		값		항목		값		
	평균		25,946		평균		24,307		평균		1.1428		
	중앙값				중앙값				중앙값		1.0734		
	최소		7,111		최소		600		최소		0.3179		
	최대		424,852		최대		910,558		최대		21.5731		
	↓ 전세 통계 (만원)												
	GBR - 12개월 기준			MLP fair_value 통계			VFM 지수 - 12개월						
	항목		값		항목		값		항목		값		
	평균		24,471		평균		24,395		평균		1.0958		
	중앙값				중앙값				중앙값		1.0232		
	최소		3,272		최소		175		최소		0.1855		
	최대		373,490		최대		735,000		최대		42.0109		
5. 검증													
분석 검증 방안		과거 데이터를 순차적으로 누적하여 학습시키고, 바로 다음 연도의 미학습 데이터를 예측하는 방식으로 모델의 시계열적 안정성을 검증											
		1. 1차: 2014~2019년 데이터 학습 → 2020년 집값 예측											
		2. 2차: 2014~2020년 데이터 학습 → 2021년 집값 예측											
		3. 3차: 2014~2021년 데이터 학습 → 2022년 집값 예측											
		4. 4차: 2014~2022년 데이터 학습 → 2023년 집값 예측											
분석 검증 방안		5. 5차: 2014~2023년 데이터 학습 → 2024년 집값 예측											
		실제 적용 검증 방식											
		학습 기간: 2015-10-01 ~ 2023-02-01 (80%)											
		테스트 기간: 2023-02-01 ~ 2024-12-01 (20%)											
		검증 방식: 시계열 순서 유지 (Shuffle 없음)											
분석 평가 결과		평가 항목		결과									
		최종 분석 시점		2024-12-01									
		분석 대상 격자수		5,832개									
		평균 월세R ² Score		0.780									
		평균 전세R ² Score		0.807									
		평균 MAE		8.025만원									